MACHINE LEARNING • KLASIFIKASI MULTIKELAS

Klasifikasi Harga Ponsel Berdasarkan Spesifikasi

Dataset Mobile Price Classification (Kaggle) dengan Logistic Regression, Decision Tree, dan Random Forest

1. 2401020016 - Dhini Khairunnisa
2. 2401020021 - Erlinda Amira Putri Sudarmono
3. 2401020030 - Nikita Arzetty Siregar
4. 2401020041 - Rismayanti

Dosen pengampu: Marisha Pertiwi, S.Tr.Kom., M.Kom

LATAR BELAKANG

Mengapa Harga Ponsel Perlu Diprediksi?

Harga ponsel dipengaruhi banyak spesifikasi sekaligus: RAM, baterai, resolusi layar, memori internal, kamera, dan lainnya.

Pembeli dan penjual membutuhkan cara cepat untuk menempatkan sebuah ponsel ke kelas harga yang sesuai.

Machine learning dapat mempelajari pola antara spesifikasi dan harga dari data historis, lalu memakainya untuk ponsel baru.

RUMUSAN MASALAH

1. Fungsi machine learning apa yang cocok untuk data Mobile Price?
2. Dari tiga algoritma yang dibandingkan, mana yang paling akurat?
3. Spesifikasi apa yang paling menentukan kelas harga?

FUNGSI MACHINE LEARNING

Memilih Fungsi ML yang Tepat untuk Data Ini

Fungsi	Keluaran	Contoh algoritma	Untuk data Mobile Price
Klasifikasi	**Label / kategori**	**Logistic Regression, Decision Tree, Random Forest, SVM**	**DIPAKAI: target price_range berupa 4 kelas**
Regresi	Angka kontinu	Linear Regression, Ridge/Lasso, Random Forest Regressor	Tidak: data hanya punya kelas harga (0-3), bukan harga dalam angka
Prediksi	Nilai / label data baru	Payung dari regresi, klasifikasi, dan time series	Hasil akhirnya: memprediksi kelas harga ponsel baru
Clustering	Kelompok tanpa label	K-Means, Hierarchical, DBSCAN	Tidak: label harga sudah tersedia
Anomaly detection	Data yang menyimpang	Isolation Forest, One-Class SVM	Tidak: tujuannya bukan mencari data ganjil
Recommendation	Saran item	Collaborative / content-based filtering	Tidak: tidak ada data preferensi pengguna
Feature extraction	Fitur baru dari data mentah	PCA, TF-IDF	Tidak utama: 20 fitur sudah berupa angka

JENIS KLASIFIKASI

Data Ini Termasuk Klasifikasi Multikelas

Biner

Menyortir data ke dalam dua kategori: positif atau negatif, ya atau tidak.

CONTOH

Email spam atau bukan spam.

DIPAKAI PADA DATA INI

Multikelas

Menyortir data ke lebih dari dua kategori yang saling terpisah; tiap data masuk tepat satu kelas.

CONTOH

Gambar hewan: anjing, kucing, atau llama.

Multilabel

Satu data boleh punya lebih dari satu label, karena kategorinya tidak saling eksklusif.

CONTOH

Artikel bertopik politik, ekonomi, dan teknologi sekaligus.

Tidak seimbang

Jumlah data antarkategori tidak merata, sehingga model cenderung bias ke kelas mayoritas.

CONTOH

95% data tidak fraud dan hanya 5% fraud.

Pada data Mobile Price, setiap ponsel masuk tepat satu dari 4 kelas harga (Murah, Menengah, Mahal, Sangat Mahal), jadi ini klasifikasi multikelas. Tiap kelas berisi 500 data, sehingga bukan kasus data tidak seimbang.

JENIS DATA

Data Tabular dan Klasifikasi Multikelas

2.000
ponsel (baris data)

20
fitur spesifikasi

4
kelas harga, masing-masing 500 data

JENIS DATA: TABULAR

14 fitur numerik (RAM, battery_power, px_width, dan lainnya) dan 6 fitur biner 0/1 (wifi, 4G, dual SIM, dan lainnya).

Bukan data gambar, teks, atau deret waktu, jadi tidak perlu ekstraksi fitur khusus.

MENGAPA KLASIFIKASI MULTIKELAS

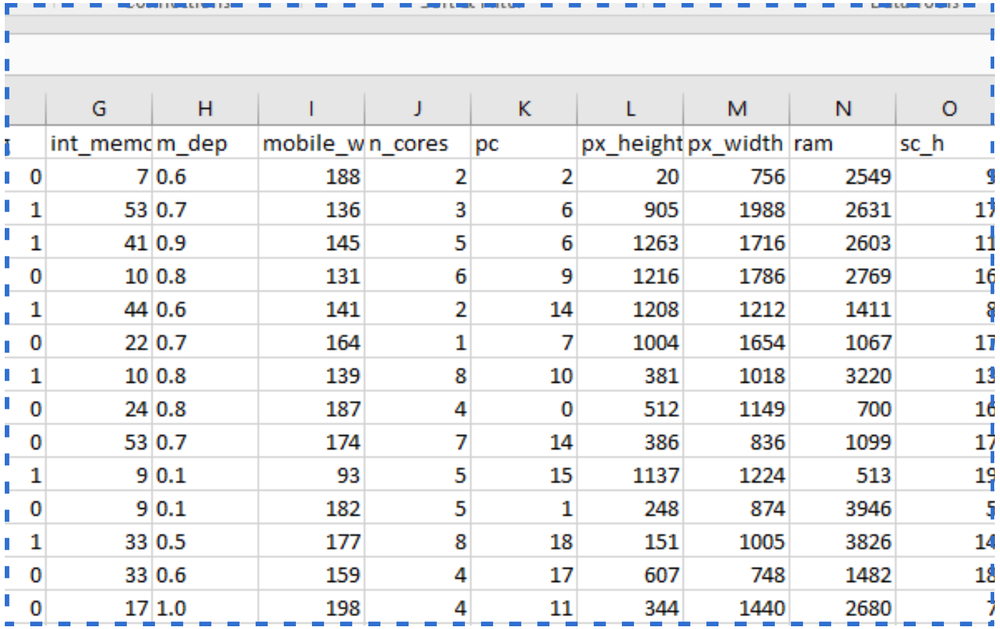
Target price_range adalah 4 kategori yang saling terpisah (0 = murah sampai 3 = sangat mahal), bukan angka harga.

Kelas seimbang, sehingga accuracy tetap layak dipakai bersama metrik lainnya.

CUPLIKAN DATA

20 Fitur Spesifikasi dan 1 Target

Kelompok	Fitur
Performa	ram, clock_speed, n_cores
Memori	int_memory
Baterai	battery_power, talk_time
Kamera	pc (belakang), fc (depan)
Layar	px_height, px_width, sc_h, sc_w, touch_screen
Fisik	mobile_wt, m_dep
Konektivitas	blue, wifi, three_g, four_g, dual_sim
Target	**price_range (0 = Murah sampai 3 = Sangat Mahal)**



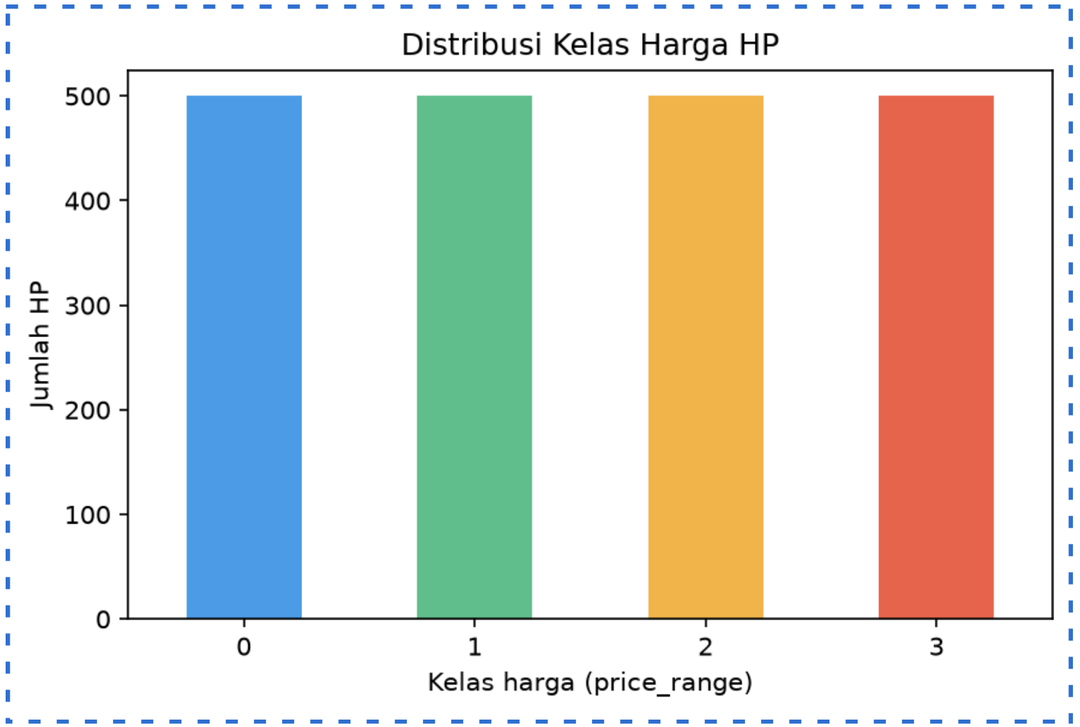
	G	H	I	J	K	L	M	N	O
	int_memo	m_dep	mobile_w	n_cores	pc	px_height	px_width	ram	sc_h
0	7	0.6	188	2	2	20	756	2549	9
1	53	0.7	136	3	6	905	1988	2631	17
1	41	0.9	145	5	6	1263	1716	2603	11
0	10	0.8	131	6	9	1216	1786	2769	16
1	44	0.6	141	2	14	1208	1212	1411	8
0	22	0.7	164	1	7	1004	1654	1067	17
1	10	0.8	139	8	10	381	1018	3220	13
0	24	0.8	187	4	0	512	1149	700	16
0	53	0.7	174	7	14	386	836	1099	17
1	9	0.1	93	5	15	1137	1224	513	19
0	9	0.1	182	5	1	248	874	3946	5
1	33	0.5	177	8	18	151	1005	3826	14
0	33	0.6	159	4	17	607	748	1482	18
0	17	1.0	198	4	11	344	1440	2680	7

14 fitur bernilai angka dan 6 fitur biner 0/1: blue, dual_sim, four_g, three_g, touch_screen, wifi.

DATASET DAN METODE

Data Spesifikasi Ponsel, 4 Kelas Harga

- Sumber: Kaggle, Mobile Price Classification
- 2.000 ponsel, 20 fitur, tanpa data kosong
- Target price_range: 4 kelas (0 Murah, 1 Menengah, 2 Mahal, 3 Sangat Mahal)
- Tiap kelas 500 data (seimbang)
- Data dibagi 80% latih dan 20% uji (acak berimbang per kelas, random_state = 42)
- Model: Logistic Regression (dengan StandardScaler), Decision Tree (max_depth = 8), Random Forest (200 pohon)
- Metrik: Accuracy, Precision, Recall, F1 (rata-rata makro)



ALUR PENELITIAN

Dari Data Mentah sampai Kesimpulan

1

Ambil data

Dataset Mobile Price dari Kaggle, 2.000 ponsel

2

Periksa data

Tidak ada data kosong, tiap kelas 500 data

3

Bagi data

80% latih (1.600) dan 20% uji (400), pembagian berimbang per kelas

4

Latih 3 model

Logistic Regression (fitur distandarisasi), Decision Tree, Random Forest

5

Evaluasi

Accuracy, Precision, Recall, F1, confusion matrix, feature importance

Ketiga model dilatih dan diuji pada data yang sama, sehingga perbandingan hasilnya adil. Standarisasi fitur hanya dipakai pada Logistic Regression.

ALGORITMA

Tiga Algoritma yang Dibandingkan

Logistic Regression

CARA KERJA

Menghitung probabilitas tiap kelas dari kombinasi linear fitur, lalu memilih kelas dengan probabilitas tertinggi. Fitur distandarisasi lebih dulu (StandardScaler).

KELEBIHAN

Sederhana, cepat, mudah dijelaskan.

KETERBATASAN

Peka terhadap skala fitur; batas antarkelas diasumsikan lurus.

Decision Tree

CARA KERJA

Membagi data lewat rangkaian pertanyaan pada fitur (misalnya "RAM di atas batas tertentu?") sampai tiba di satu kelas.

KELEBIHAN

Aturannya mudah dibaca seperti diagram alur.

KETERBATASAN

Mudah overfitting; kedalaman pohon dibatasi (max_depth = 8).

Random Forest

CARA KERJA

Membangun banyak pohon keputusan dari sampel data acak (di sini 200 pohon), lalu kelas akhir ditentukan lewat pemungutan suara.

KELEBIHAN

Lebih stabil daripada satu pohon dan menghasilkan feature importance.

KETERBATASAN

Lebih berat dan sulit ditelusuri per keputusan.

Walau namanya regresi, Logistic Regression (regresi logistik) dipakai untuk klasifikasi: targetnya kategori, bukan angka.

METRIK EVALUASI

Cara Mengukur Kualitas Model

Accuracy

Proporsi tebakan yang benar dari seluruh data uji.

Precision

Dari ponsel yang ditebak masuk satu kelas, berapa yang benar-benar di kelas itu.

Recall

Dari ponsel yang sebenarnya di satu kelas, berapa yang berhasil ditemukan.

F1-Score

Rata-rata harmonik Precision dan Recall.

DIBACA BERSAMA

Rata-rata makro: metrik dihitung per kelas lalu dirata-ratakan, jadi keempat kelas diperlakukan sama.

Confusion matrix: tabel tebakan versus kenyataan yang menunjukkan kelas mana yang sering tertukar.

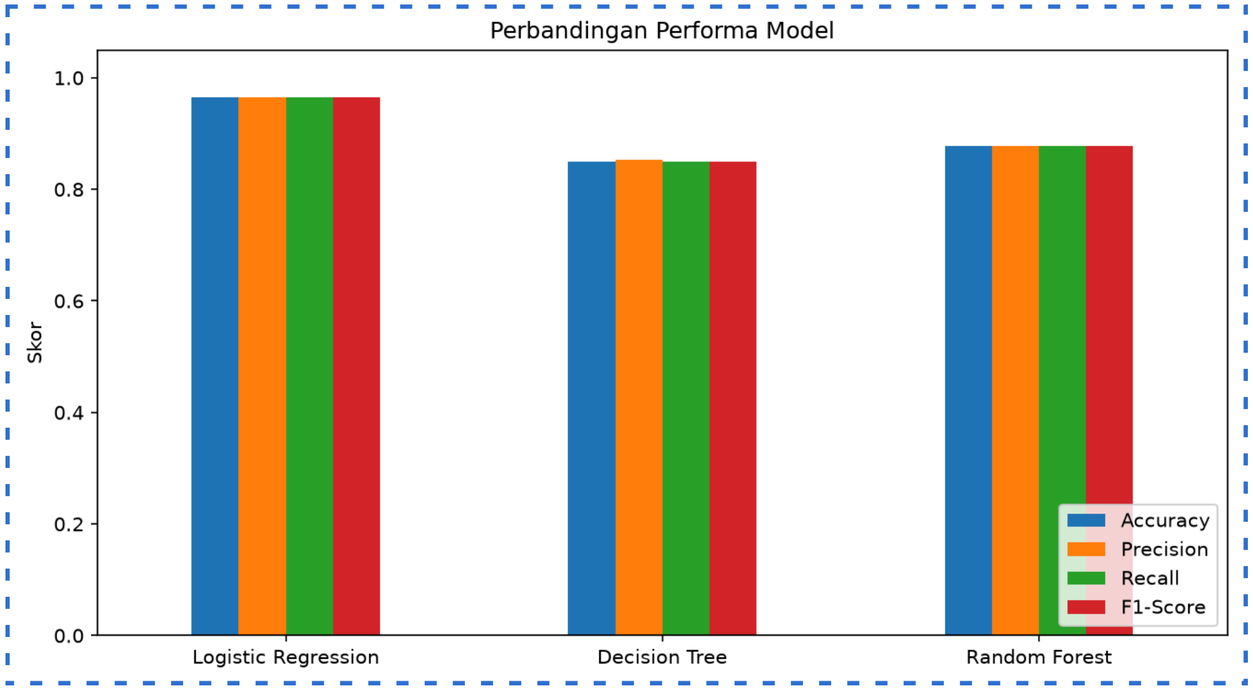
Karena kelas seimbang, accuracy tidak menyesatkan seperti pada data tidak seimbang; metrik lain tetap dilaporkan sebagai pelengkap.

HASIL

Perbandingan Tiga Model

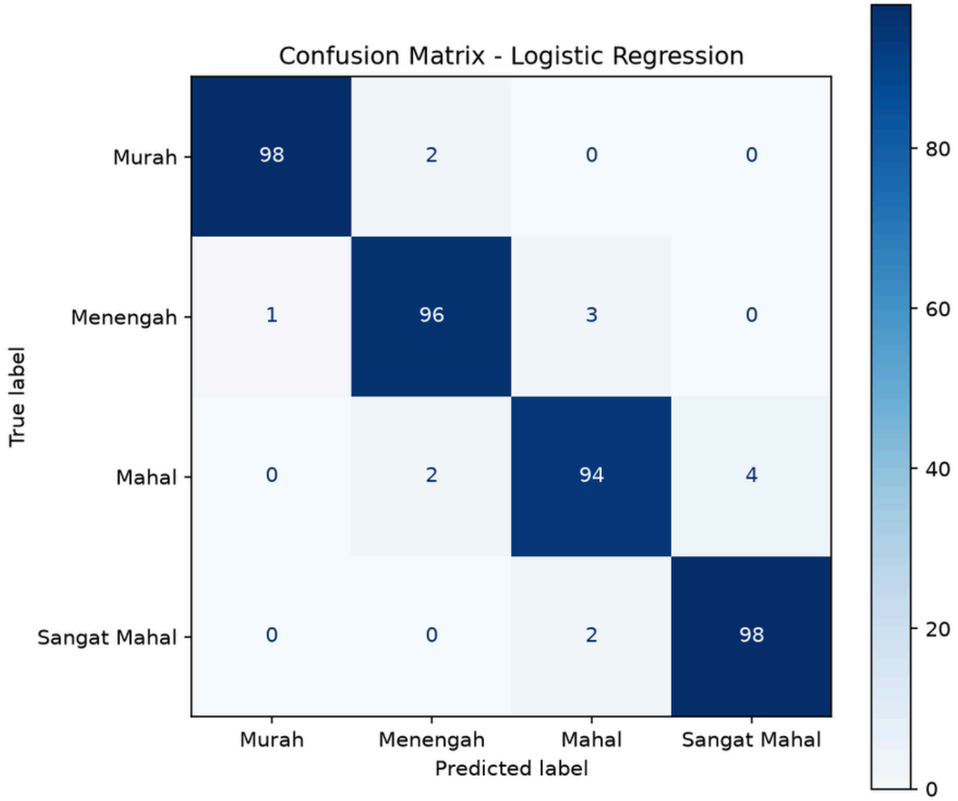
Model	Accuracy	Precision	Recall	F1
Logistic Regression	**0,965**	**0,965**	**0,965**	**0,965**
Random Forest	0,878	0,878	0,878	0,877
Decision Tree	0,850	0,852	0,850	0,850

Logistic Regression paling baik (F1 = 0,965). Hubungan antara spesifikasi dan harga cukup lurus dan fitur sudah distandarisasi, sehingga model sederhana pun sudah akurat.



EVALUASI

Confusion Matrix: Logistic Regression

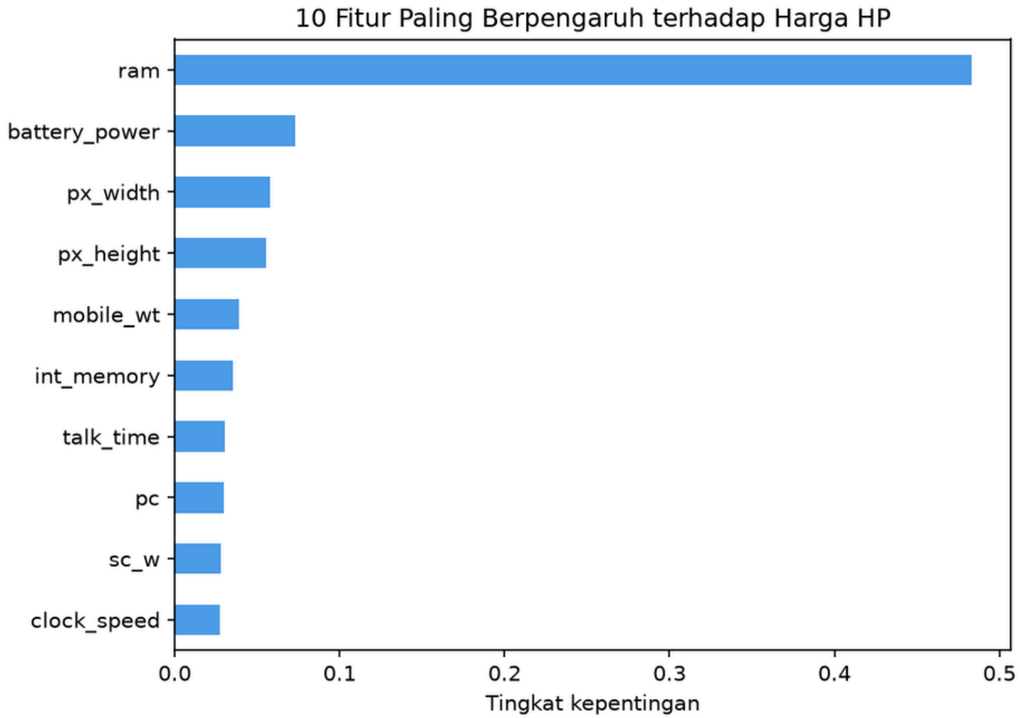


- 386 dari 400 ponsel uji ditebak benar (96,5%)
- Hanya 14 kesalahan, seluruhnya jatuh ke kelas yang bersebelahan (paling banyak Mahal tertukar dengan Sangat Mahal, 4 kali)
- Kelas Murah dan Sangat Mahal paling mudah dikenali (masing-masing 98 dari 100 benar)
- Kelas Mahal paling sering salah (94 dari 100 benar)

FAKTOR PENENTU HARGA

RAM Paling Berpengaruh

- Menurut Random Forest, RAM jauh di atas fitur lain (sekitar 48% dari total kepentingan)
- Disusul battery_power (sekitar 7%), px_width dan px_height (masing-masing sekitar 6%)
- Sejalan dengan tiga jurnal pembanding [1][2][3]: RAM paling terkait dengan kelas harga
- Artinya: ponsel dengan RAM besar cenderung masuk kelas harga tinggi. Feature importance menunjukkan kontribusi fitur pada model, bukan sebab-akibat



JURNAL PENDUKUNG

Perbandingan dengan Penelitian Terdahulu

Model	Hasil kami	Sunariya dkk. [1]	Ramadhan dkk. [2]	Ardelia dkk. [3]
Logistic Regression	96,5%	85,5%	-	97% (80:20), 98% (90:10)
Random Forest	87,8%	88,8%	-	-
Decision Tree	85,0%	80,5%	81%	-

- Random Forest (87,8%) dan Decision Tree (85,0%) kami berada di kisaran jurnal, yaitu 80-89% [1][2]
- Logistic Regression kami (96,5%) mendekati Ardelia dkk. [3] yang memakai tuning hyperparameter (GridSearchCV)
- Sunariya dkk. [1] mencatat SVM terbaik (98%). Perbedaan angka dapat dipengaruhi pra-pemrosesan dan pembagian data tiap penelitian
- Fatah dkk. [5] memakai Decision Tree pada 64 data ponsel (bukan 2.000 data Kaggle) dengan akurasi 97%, sehingga tidak dibandingkan langsung

PENUTUP

Kesimpulan dan Saran

- Fungsi ML yang cocok: klasifikasi multikelas, karena target price_range berupa 4 kelas harga
- Model terbaik: Logistic Regression (accuracy dan F1 96,5%), di atas Random Forest (87,8%) dan Decision Tree (85,0%)
- Faktor paling menentukan harga: RAM (sekitar 48% kepentingan), disusul battery_power dan resolusi layar
- Data rapi dan seimbang, jadi hasil setinggi ini belum tentu terulang pada data dunia nyata
- Saran: coba SVM, tuning hyperparameter (GridSearchCV), dan data yang lebih beragam

Daftar Pustaka

[1] N. Sunariya, A. Singh, M. Alam, V. Gaur, "Classification of Mobile Price Using Machine Learning," CEUR Workshop Proceedings, vol. 3682, SCI 2024, New Delhi.

[2] A. T. Ramadhan, F. H. F. G., N. R. Puteri, A. Meirza, "Penerapan Algoritma Decision Tree dalam Melakukan Analisis Klasifikasi Harga Handphone," JUSIIK, vol. 1, no. 4, pp. 195-206, 2023.

[3] D. N. Ardelia, H. D. Arifin, S. Daniswara, A. P. Sari, "Klasifikasi Harga Ponsel Menggunakan Algoritma Logistic Regression," J. Informatics and Electronics Engineering, vol. 4, no. 1, pp. 37-43, Jun. 2024.

[4] Kaggle, "Mobile Price Classification." kaggle.com/datasets/iabhishekofficial/mobile-price-classification

[5] Z. Fatah, A. F. Haq, "Klasifikasi Harga Handphone Menggunakan Algoritma Decision Tree," JAMASTIKA, vol. 5, no. 1, pp. 202-208, Apr. 2026.